

Cyfrowe przetwarzanie sygnałów i obrazów

Laboratorium nr 1 - Przetwarzanie i analiza sygnału EKG

Autorzy:

Imię i nazwisko	Numer indeksu
Maksymilian Tara	264000
Łukasz Gawron	264475

```
In [ ]: %matplotlib widget
import numpy as np
import matplotlib.pyplot as plt
import math
import scipy.signal as sig

data_ekg1 = None
data_ekg_100 = None
data_ekg_noise = None

ekg1_time = None
ekg_100_time = None
ekg_noise_time = None

sampling_frequency_ekg1 = 1000
sampling_frequency_ekg_100 = 360
sampling_frequency_ekg_noise = 360
```

Zadanie nr 1

Napisz skrypt w Pythonie/Matlabie umożliwiający wczytywanie i wizualizację badanych sygnałów. Program powinien umożliwiać obserwowanie wycinka sygnału dla zadanego przedziału czasowego, skalowanie osi wykresów i ich opis oraz zapis dowolnego wycinka sygnału do pliku o podanej nazwie.

Dane:

- ekg1.txt – 12 kolumn odpowiada odprowadzeniom, fs = 1000 Hz
- ekg100.txt – 1 kolumna, fs = 360 Hz
- ekg_noise.txt – 1 kolumna: czas, 2 kolumna: wartości amplitud EKG, fs = 360 Hz

Poniżej znajdują się funkcje, wykorzystane do wczytania badanych sygnałów z pliku o nazwie podawanej w argumencie. Pierwsza funkcja służy wczytaniu danych o wartościach całkowito-liczbowych, natomiast druga funkcja służy wczytaniu danych o wartościach zmiennie-przecinkowych.

```
In [ ]: def load_signal_int_values_sampled(file_path: str):
    signal_data = []
    with open(file_path, "r+") as file:
        while True:
            line = file.readline()
            if not line:
                break
            values_row = line.lstrip().split()
            values_row = np.array(list(map(int, values_row)))

            signal_data.append(values_row)

    signal_data = np.array(signal_data)
    return np.array(signal_data)

def load_signal_float_values_sampled(file_path: str):
    signal_data = []
    with open(file_path, "r+") as file:
        while True:
            line = file.readline()
            if not line:
                break
            values_row = line.lstrip().split()
            values_row = np.array(list(map(float, values_row)))

            signal_data.append(values_row)

    signal_data = np.array(signal_data)
    return np.array(signal_data)
```

```
In [ ]: global data_ekg1, ekg1_time, sampling_frequency_ekg1

data_ekg1 = load_signal_int_values_sampled("./resources/ekg1.txt")
ekg1_time = np.arange(len(data_ekg1)) / sampling_frequency_ekg1

plt.figure(figsize=(12, 6))
plt.legend(loc="upper left")


for i in range(len(data_ekg1[0])):
    plt.plot(ekg1_time, data_ekg1[:, i])

plt.legend(["Column " + str(i + 1) for i in range(len(data_ekg1[0]))])
plt.title('ekg1.txt')
plt.xlabel('Czas[s]')
plt.ylabel('Wartość')
plt.xlim(ekg1_time[0], ekg1_time[len(ekg1_time) - 1])

plt.show()
```

No artists with labels found to put in legend. Note that artists whose label start with an underscore are ignored when legend() is called with no argument.

Figure




```
In [ ]: global data_ekg_100, ekg_100_time, sampling_frequency_ekg_100

data_ekg_100 = load_signal_float_values_sampled("./resources/ekg_100.txt")
ekg_100_time = np.arange(
    len(data_ekg_100)) / sampling_frequency_ekg_100

fig, (ax1, ax2) = plt.subplots(2, 1, figsize=(12, 12))
ax1.plot(ekg_100_time, data_ekg_100)
ax1.set_title('ekg_100.txt - całość')
ax1.set_xlabel('Czas [s]')
ax1.set_ylabel('Amplituda')
ax1.legend(["Column " + str(i + 1) for i in range(len(data_ekg_100[0]))])
ax1.set_xlim(ekg_100_time[0], ekg_100_time[-1])

ax2.plot(ekg_100_time, data_ekg_100)
ax2.set_title('ekg_100.txt - fragment 3 okresów')
ax2.set_xlabel('Czas [s]')
ax2.set_ylabel('Amplituda')
ax2.legend(["Column " + str(i + 1) for i in range(len(data_ekg_100[0]))])
ax2.set_xlim(ekg_100_time[0], 2)

plt.tight_layout()
plt.show()
```



```
In [ ]: global data_ekg_noise, ekg_noise_time, sampling_frequency_ekg_noise

data_ekg_noise = load_signal_float_values_sampled("./resources/ekg_noise.txt")

plt.figure(figsize=(12, 6))
plt.legend(loc="upper left")


plt.plot(data_ekg_noise[:, 0], data_ekg_noise[:, 1])

plt.legend(["Column " + str(i + 1) for i in range(len(data_ekg_noise[0]))])
plt.title('ekg_noise.txt')
plt.xlabel('Czas[s]')
plt.ylabel('Wartość')
plt.xlim(data_ekg_noise[:, 0][0],
          data_ekg_noise[:, 0][data_ekg_noise[:, 0].size - 1])

plt.show()
```

No artists with labels found to put in legend. Note that artists whose label start with an underscore are ignored when legend() is called with no argument.

Figure



Zadanie nr 2

Celem ćwiczenia jest praktyczne wypróbowanie funkcji `numpy.fft` i `numpy.ifft` do wyznaczania prostej i odwrotnej transformaty Fouriera

Generowanie sygnału

Poniżej znajduje się funkcja służąca do generowania ciągu próbek mieszanych dowolnej ilości fal sinusoidalnych. Pierwszym argumentem jest lista częstotliwości, z jakich chcemy stworzyć sygnał. Drugim argumentem długość sygnału, trzecim argumentem jest czas próbkowania (odwrotność częstotliwości próbkowania).

```
In [ ]: # funkcja służąca do generowania sygnału sinusoidalnego o zadanych częstotliwościach
# parametry: [częstotliwość], długość, 1/fs
def generate_signal(frequencyArray, length, time_period):
    if len(frequencyArray) == 0:
        return None
    time = np.arange(length)
    signal = np.sin(2 * np.pi * frequencyArray[0] * time * time_period)
    if (len(frequencyArray) == 1):
        return signal

    for i in range(1, len(frequencyArray)):
        signal += np.sin(2 * np.pi * frequencyArray[i] * time * time_period)

    return signal
```

Transformata Fouriera

Poniżej znajduje się funkcja służąca wyznaczaniu dyskretnej transformaty Fouriera z zadanego sygnału. Pierwszym argumentem jest ciąg próbek sygnału, drugim argumentem jest długość sygnału, natomiast trzecim argumentem jest częstotliwość próbkowania.

```
In [ ]: # funkcja służąca do przetwarzania sygnału za pomocą transformaty Fouriera
# parametry: sygnał, długość, fs
def fourier_transform(signal, length, sampling_rate):
    dft_result = np.fft.fft(signal)
    freq = np.fft.fftfreq(length, 1/sampling_rate)
    positive_freq_indices = np.where(freq >= 0)
    amplitudes = np.abs(dft_result) / length
    amplitudes *= 2
    return freq, amplitudes, positive_freq_indices
```


1. Wygeneruj ciąg próbek odpowiadający fali sinusoidalnej o częstotliwości 50 Hz i długości 65536.

```
In [ ]: frequency = 50          # f = 50 Hz
length = 65_536
time = np.arange(length)
sampling_rate = 2000          # fs = 2 kHz
time_period = 1/sampling_rate # t = 1/fs

sinusoidal_signal = np.sin(
    2 * np.pi * frequency * time * time_period) # sin(2 * pi * f * t)

plt.figure(figsize=(12, 6))
plt.plot(time, sinusoidal_signal)
plt.title('Sygnał sinusoidalny')
plt.ylabel('Amplituda')
plt.xlabel('Numer próbek')
plt.xlim(0, sampling_rate / 2)
plt.axhline(y=0, color='black')
plt.grid(True)
plt.show()
```

Figure




2. Wyznacz dyskretną transformatę Fouriera tego sygnału i przedstaw jego widmo amplitudowe na wykresie w zakresie częstotliwości $[0, f_s/2]$, gdzie f_s oznacza częstotliwość próbkowania.

```
In [ ]: # Dyskretna Transformata Fouriera (DFT)
dft_result = np.fft.fft(sinusoidal_signal)
# Obliczenie częstotliwości
freq = np.fft.fftfreq(length, 1/sampling_rate)
# Indeksy częstotliwości do narysowania (0 do fs/2)
positive_freq_indices = np.where(freq >= 0)
# Widmo amplitudowe
# Normalizacja przez długość sygnału
amplitudes = np.abs(dft_result) / length
# Podwojenie amplitud (z uwzględnieniem symetrii)
amplitudes *= 2

# Narysowanie widma amplitudowego
plt.figure(figsize=(12, 6))
plt.plot(freq[positive_freq_indices], amplitudes[positive_freq_indices])
plt.title('Widmo Amplitudowe')
plt.xlabel('Częstotliwość [Hz]')
plt.ylabel('Amplituda')
plt.xlim(0, sampling_rate / 2) # Zakres częstotliwości [0, fs/2]
plt.grid(True)
plt.show()
```

Figure



3. Wygeneruj ciąg próbek mieszanki dwóch fal sinusoidalnych (tzn. ich kombinacji liniowej) o częstotliwościach 50 i 60 Hz. Wykonaj zadanie z punktu 2 dla tego sygnału.

```
In [ ]: frequency_1 = 50
frequency_2 = 60
length = 65_536
time = np.arange(length)
sampling_rate = 2000      # fs = 2 kHz
time_period = 1/sampling_rate    # t = 1/fs


mixed_signal = generate_signal([frequency_1, frequency_2], length, time_period)

plt.figure(figsize=(12, 6))
plt.plot(time, mixed_signal)
plt.title('Sygnał sinusoidalny')
plt.ylabel('Amplituda')
plt.xlabel('Numer próbek')
plt.xlim(0, sampling_rate / 2)
plt.axhline(y=0, color='black')
plt.grid(True)
plt.show()

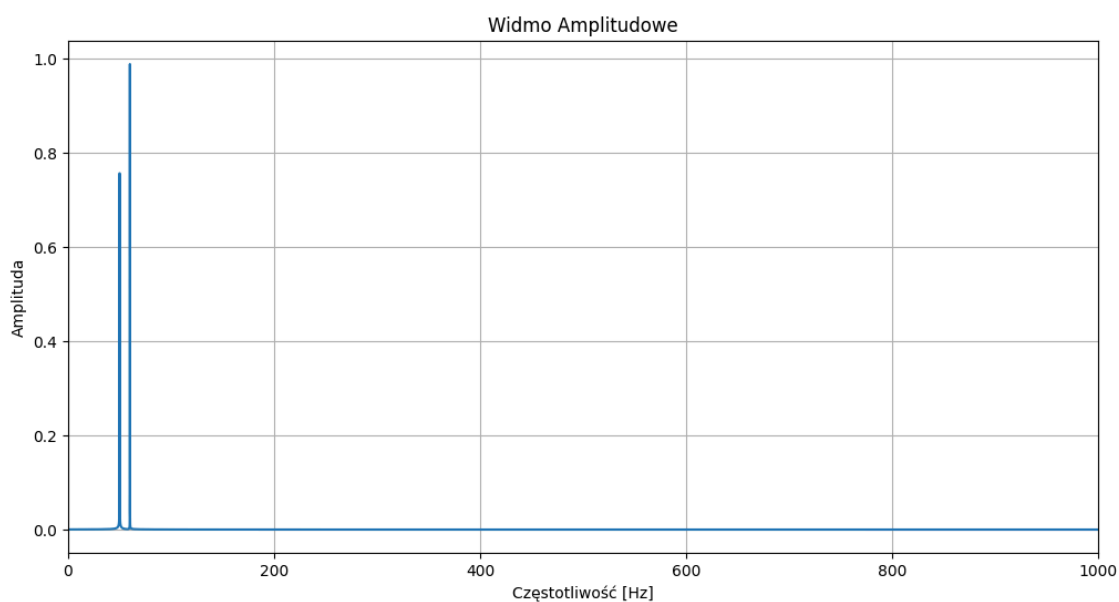
freq, amplitudes, positive_freq_indices = fourier_transform(
    mixed_signal, length, sampling_rate)

# Narysowanie widma amplitudowego
plt.figure(figsize=(12, 6))
plt.plot(freq[positive_freq_indices], amplitudes[positive_freq_indices])
plt.title('Widmo Amplitudowe')
plt.xlabel('Częstotliwość [Hz]')
plt.ylabel('Amplituda')
plt.xlim(0, sampling_rate / 2) # Zakres częstotliwości [0, fs/2]
plt.grid(True)
plt.show()
```


Figure



Figure



4. Powtórz eksperymenty dla różnych czasów trwania sygnałów, tzn. dla różnych częstotliwości próbkowania.

```
In [ ]: frequency_1 = 50
frequency_2 = 60
length = 65_536
time = np.arange(length)

# Częstotliwość próbkowania 200 Hz
sampling_rate = 200
time_period = 1/sampling_rate      # t = 1/fs
mixed_signal = generate_signal([frequency_1, frequency_2], length, time_period)

freq, amplitudes, positive_freq_indices = fourier_transform(
```

```

    mixed_signal, length, sampling_rate)
# Narysowanie widma amplitudowego
plt.figure(figsize=(12, 6))
plt.plot(freq[positive_freq_indices], amplitudes[positive_freq_indices])
plt.title('Widmo Amplitudowe, fs = 200 Hz')
plt.xlabel('Częstotliwość [Hz]')
plt.ylabel('Amplituda')
plt.xlim(0, sampling_rate / 2) # Zakres częstotliwości [0, fs/2]
plt.grid(True)
plt.show()


# Częstotliwość próbkowania 5 kHz
sampling_rate = 5000
time_period = 1/sampling_rate # t = 1/fs
mixed_signal = generate_signal([50, 60], length, time_period)

freq, amplitudes, positive_freq_indices = fourier_transform(
    mixed_signal, length, sampling_rate)

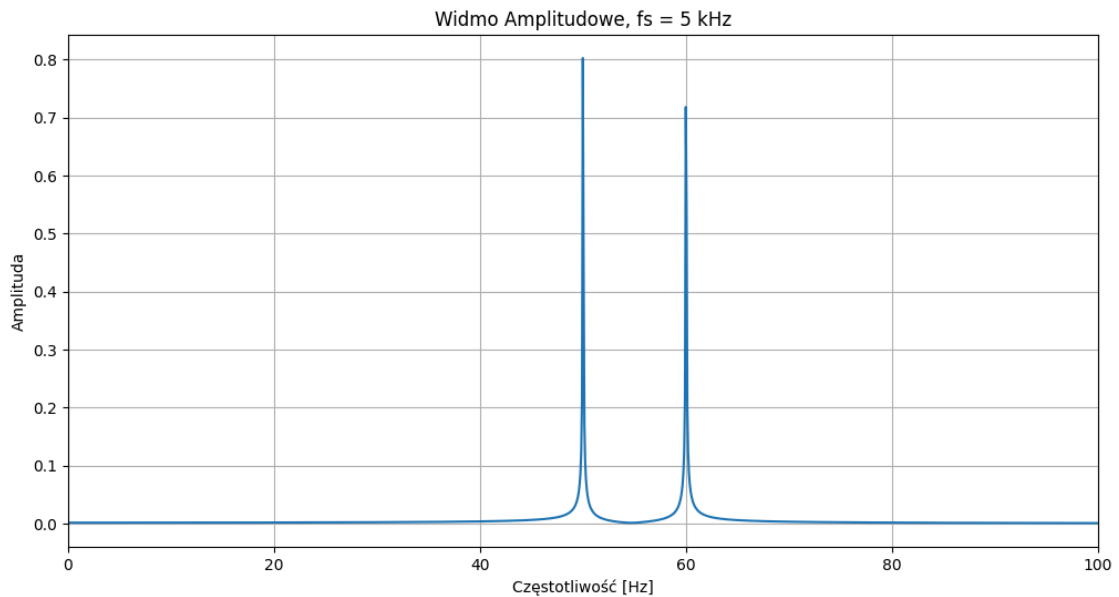
plt.figure(figsize=(12, 6))
plt.plot(freq[positive_freq_indices], amplitudes[positive_freq_indices])
plt.title('Widmo Amplitudowe, fs = 5 kHz')
plt.xlabel('Częstotliwość [Hz]')
plt.ylabel('Amplituda')
plt.xlim(0, 100)
plt.grid(True)
plt.show()

```

Figure



Figure



5. Wyznacz odwrotne transformaty Fouriera ciągów wyznaczonych w zadaniu 2 i porównaj z ciągami oryginalnymi.

```
In [ ]: frequency = 50 # Hz

length = 65536
sampling_rate = 1000 # Hz

# Czas trwania sygnału
time = np.arange(length)

# Wygenerowanie fali sinusoidalnej
sinusoidal_signal = np.sin(2 * np.pi * frequency * time / sampling_rate)

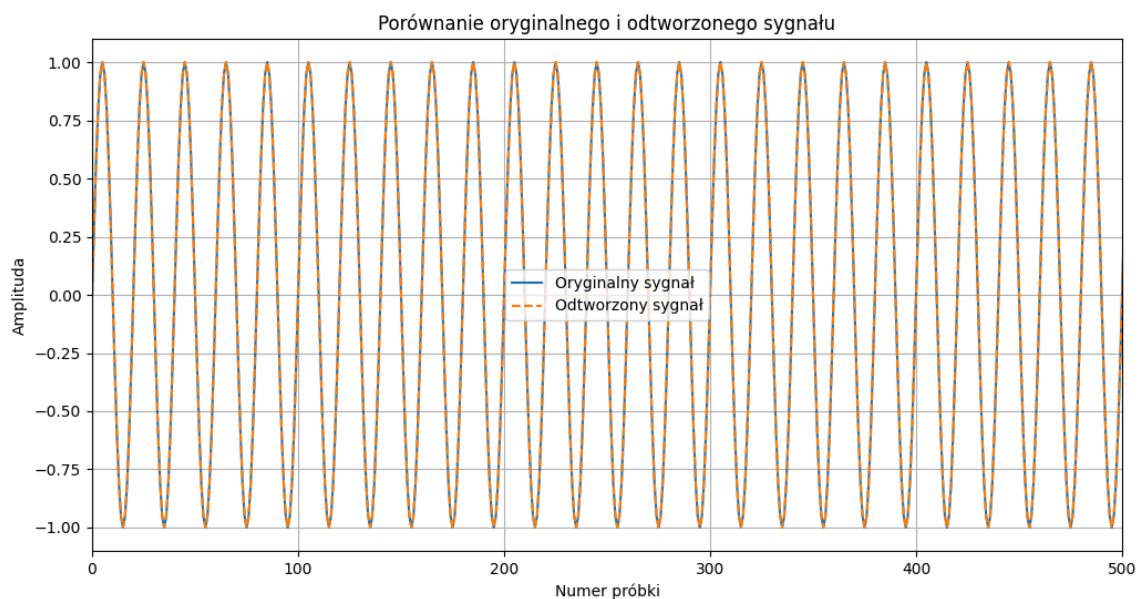
# Dyskretna Transformata Fouriera (DFT)
dft_result = np.fft.rfft(sinusoidal_signal)

# Obliczenie częstotliwości
freq = np.fft.rfftfreq(length, 1/sampling_rate)

# IDFT - Odwrotna Dyskretna Transformata Fouriera
reconstructed_signal = np.fft.irfft(dft_result)

plt.figure(figsize=(12, 6))
plt.plot(time, sinusoidal_signal, label='Oryginalny sygnał')
plt.plot(time, reconstructed_signal,
         label='Odtworzony sygnał', linestyle='--')
plt.title('Porównanie oryginalnego i odtworzonego sygnału')
plt.xlabel('Numer próbek')
plt.ylabel('Amplituda')
plt.xlim(0, sampling_rate / 2) # Zakres częstotliwości [0, fs/2]
plt.legend()
plt.grid(True)
plt.show()
```

Figure



```
In [ ]: frequency_1 = 50
frequency_2 = 60
length = 65_536
time = np.arange(length)
sampling_rate = 2000      # fs = 2 kHz
time_period = 1/sampling_rate # t = 1/fs


mixed_signal = generate_signal([frequency_1, frequency_2], length, time_period)

dft_result = np.fft.rfft(mixed_signal)

reconstructed_signal = np.fft.irfft(dft_result)

plt.figure(figsize=(12, 6))
plt.plot(time, mixed_signal, label='Oryginalny sygnał')
plt.plot(time, reconstructed_signal,
         label='Odtworzony sygnał', linestyle='--')
plt.title('Porównanie oryginalnego i odtworzonego sygnału')
plt.xlabel('Numer próbki')
plt.ylabel('Amplituda')
plt.xlim(0, sampling_rate / 2) # Zakres częstotliwości [0, fs/2]
plt.legend()
plt.grid(True)
plt.show()
```

Figure



Zadanie nr 3

Celem ćwiczenia jest obserwacja widma sygnału EKG.


1. Wczytać sygnał ekg100.txt i ocenić go wizualnie na wykresie

```
In [ ]: global data_ekg_100, ekg_100_time

fig, (ax1, ax2) = plt.subplots(2, 1, figsize=(12, 12))
ax1.plot(ekg_100_time, data_ekg_100)
ax1.set_title('ekg_100.txt - całość')
ax1.set_xlabel('Czas [s]')
ax1.set_ylabel('Amplituda')
ax1.legend(["Column " + str(i + 1) for i in range(len(data_ekg_100[0]))])
ax1.set_xlim(ekg_100_time[0], ekg_100_time[-1])

ax2.plot(ekg_100_time, data_ekg_100)
ax2.set_title('ekg_100.txt - fragment 3 okresów')
ax2.set_xlabel('Czas [s]')
ax2.set_ylabel('Amplituda')
ax2.legend(["Column " + str(i + 1) for i in range(len(data_ekg_100[0]))])
ax2.set_xlim(ekg_100_time[0], 2)

plt.tight_layout()
plt.show()
```



2. Wyznaczyć jego dyskretną transformatę Fouriera i przedstawić widmo amplitudowe sygnału w funkcji częstotliwości w zakresie $[0, fs/2]$, gdzie fs oznacza częstotliwość próbkowania.

```
In [ ]: global data_ekg_100, ekg_100_time

length = len(data_ekg_100[:, 0])
sampling_rate = 360

# Wyznacz dyskretną transformatę Fouriera tego sygnału i przedstaw jego widmo
# amplitudowe na wykresie w zakresie częstotliwości  $[0, fs/2]$ , gdzie  $fs$  oznacza
# częstotliwość próbkowania.

# Dyskretna Transformata Fouriera (DFT)
dft_result = np.fft.rfft(data_ekg_100[:, 0])
# Obliczenie częstotliwości
freq = np.fft.rfftfreq(length, 1/sampling_rate)
```

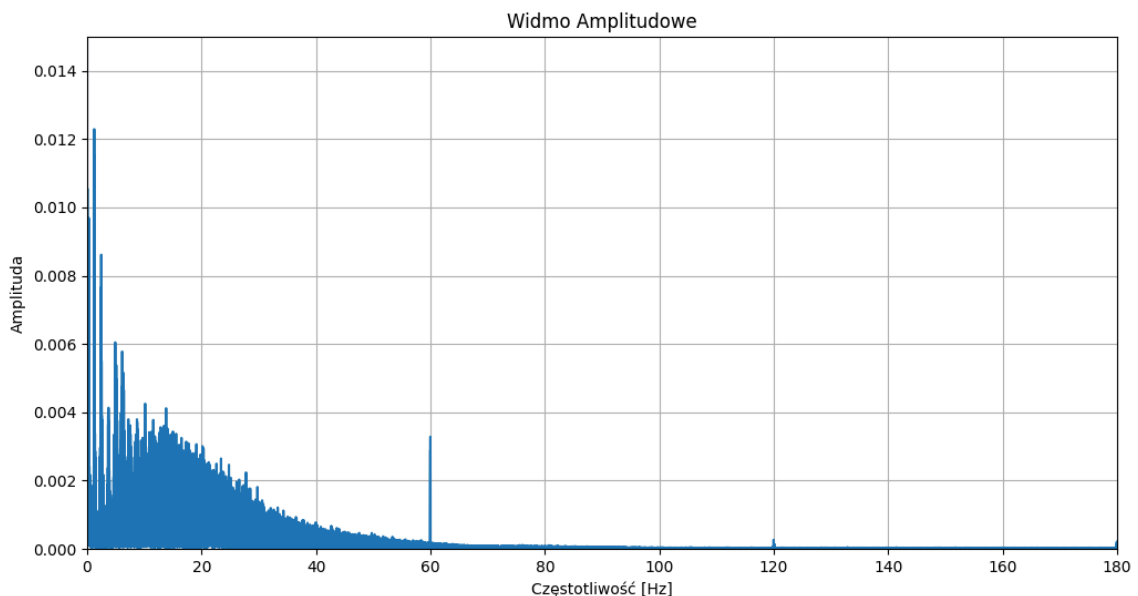
```

# Widmo amplitudowe
# Normalizacja przez długość sygnału
amplitudes = np.abs(dft_result) / length
# Podwojenie amplitud (z uwzględnieniem symetrii)
amplitudes *= 2

# Narysowanie widma amplitudowego
plt.figure(figsize=(12, 6))
plt.plot(freq, amplitudes)
plt.title('Widmo Amplitudowe')
plt.xlabel('Częstotliwość [Hz]')
plt.ylabel('Amplituda')
plt.xlim(0, sampling_rate / 2) # Zakres częstotliwości [0, fs/2]
plt.ylim(0, 0.015)
plt.grid(True)
plt.show()

```

Figure



3. Wyznaczyć odwrotną dyskretną transformatę Fouriera ciągu wyznaczonego w punkcie 2 i porównać otrzymany ciąg próbek z pierwotnym sygnałem ekg100 (można wyznaczyć różnicę sygnałów).

```

In [ ]: global data_ekg_100, ekg_100_time

length = len(dft_result)

invdft_result = np.fft.irfft(dft_result)

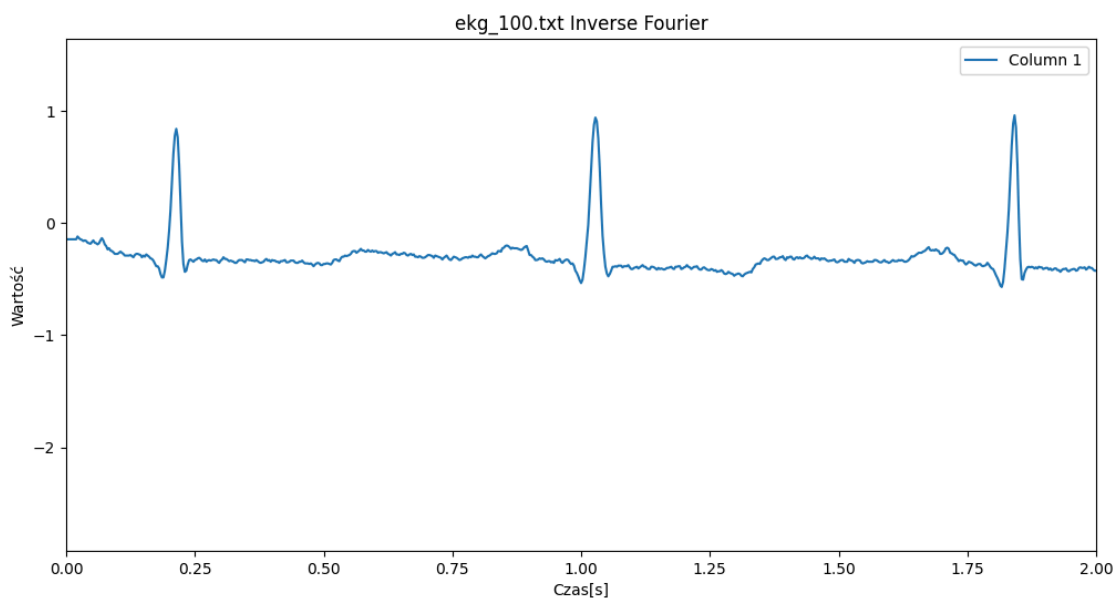
plt.figure(figsize=(12, 6))
plt.plot(ekg_100_time, invdft_result)

plt.legend(["Column " + str(i + 1) for i in range(len(data_ekg_100[0]))])
plt.title('ekg_100.txt Inverse Fourier')
plt.xlabel('Czas[s]')
plt.ylabel('Wartość')
plt.xlim(ekg_100_time[0], 2)

```

```
plt.show()
```


Figure



```
In [ ]: global data_ekg_100, ekg_100_time

roznica = data_ekg_100[:, 0] - invdft_result
plt.figure(figsize=(10, 5))
plt.plot(ekg_100_time, roznica)
plt.title('roznica przed i po odwrotnej transformacie Fouriera')
plt.xlabel('Czas[s]')
plt.ylabel('Wartość')
plt.ylim(-1, 1)
plt.grid(True)
plt.show()
```

Figure



Obserwujemy, że między sygnałem oryginalnym, a sygnałem otrzymanym z odwrotnej dyskretnej transformaty Fouriera - nie ma żadnej różnicy (Wykres różnicy to prosta o stałej wartości $y=0$)

Zadanie nr 4

Celem ćwiczenia jest praktyczne wypróbowanie działania filtrów w celu wyeliminowania niepożądanych zakłóceń z sygnału EKG. Proszę wybrać rodzaj filtra do eksperymentowania, np. Butterwortha lub Czebyszewa. Do filtracji wykorzystać gotowe funkcje z biblioteki `scipy.signal` [7]. Biblioteka posiada również funkcje wspomagające projektowanie filtrów, które można zastosować.

1. Wczytaj sygnał `ekg_noise.txt` i zauważ zakłócenia nałożone na sygnał. Wykreślić częstotliwościową charakterystykę amplitudową sygnału

```
In [ ]: global data_ekg_noise, ekg_noise_time

plt.figure(figsize=(8, 4))
plt.legend(loc="upper left")


plt.plot(data_ekg_noise[:, 0], data_ekg_noise[:, 1])

plt.legend(["Column " + str(i + 1) for i in range(len(data_ekg_noise[0]))])
plt.title('ekg_noise.txt')
plt.xlabel('Czas[s]')
plt.ylabel('Wartość')
plt.xlim(data_ekg_noise[:, 0][0], 4)

plt.show()
```

No artists with labels found to put in legend. Note that artists whose label start with an underscore are ignored when `legend()` is called with no argument.

Figure



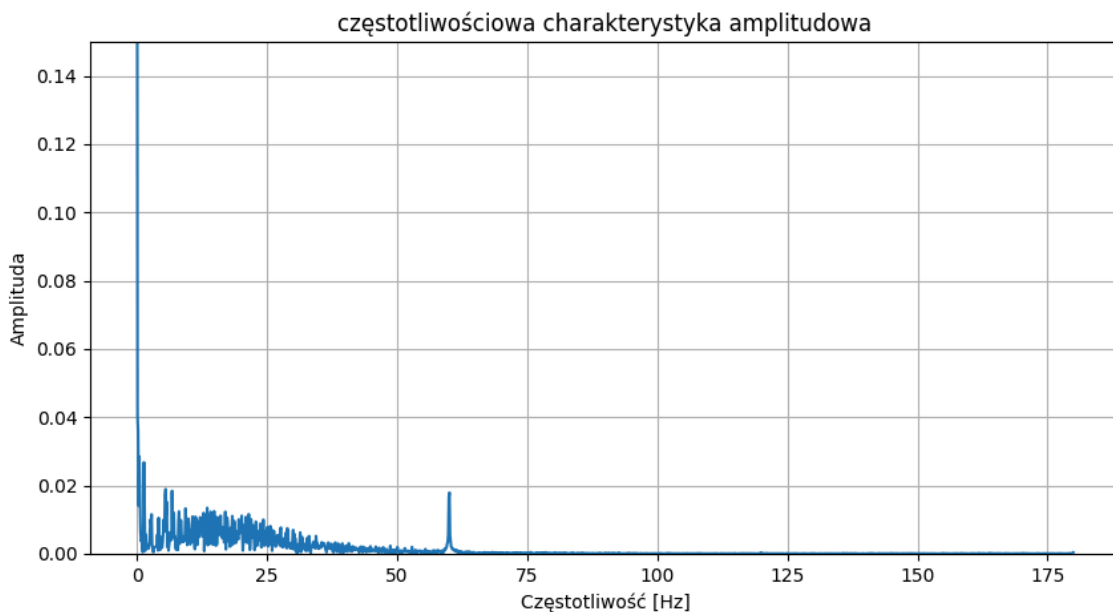
```
In [ ]: global data_ekg_noise, ekg_noise_time

length = len(data_ekg_noise)
sampling_rate = 360      # fs = 2 kHz

dft_result = np.abs(np.fft.rfft(data_ekg_noise[:, 1])) / length
freq = np.fft.rfftfreq(length, 1/sampling_rate)
#positive_freq_indices = np.where(freq >= 0)

# Narysowanie charakterystyki
plt.figure(figsize=(10, 5))
plt.plot(freq, dft_result)
plt.title('częstotliwościowa charakterystyka amplitudowa')
plt.xlabel('Częstotliwość [Hz]')
plt.ylabel('Amplituda')
plt.grid(True)
#plt.axvline(60, color='red')
plt.ylim(0, 0.15)
plt.show()
```

Figure



2. Zbadaj filtr dolnoprzepustowy o częstotliwości granicznej 60 Hz w celu redukcji zakłóceń pochodzących z sieci zasilającej. Wyznacz parametry filtra, wykreśl jego charakterystykę (zależność tłumienia od częstotliwości), przebieg sygnału po filtracji oraz jego widmo. Można też wyznaczyć różnicę między sygnałem przed i po filtracji i widmo tej różnicy.

```
In [ ]: global data_ekg_noise
sampling_rate = 360

# dolnoprzepustowy - parametry i sygnał po filtracji
sos = sig.butter(4, 60, 'lowpass', output='sos', fs=360)
filtered_data = sig.sosfilt(sos, data_ekg_noise[:, 1])

length = len(filtered_data)

plt.figure(figsize=(10, 5))
```

```
plt.plot(data_ekg_noise[:, 0], filtered_data)
plt.title('Sygnał po filtracji dolnoprzepustowym Butterwortha')
plt.xlabel('Czas[s]')
plt.ylabel('Wartość')
plt.grid(True)
plt.xlim(0, 4)
plt.show()

# wykreslenie charakterystyki filtra
b, a = sig.butter(4, 60, 'low', fs=360)
w, h = sig.freqz(b, a)
# plt.semilogx(w*360/(2*np.pi), 20 * np.log10(abs(h)))

plt.figure(figsize=(10, 5))
plt.plot(w*360/(2*np.pi), 20 * np.log10(abs(h)))
plt.title('Charakterystyka filtra')
plt.xlabel('Frequency [Hz]')
plt.ylabel('Amplitude')
plt.grid(which='both', axis='both')
plt.axvline(60, color='green') # cutoff frequency
plt.show()

# widmo sygnału po filtracji
dft_result = np.abs(np.fft.rfft(filtered_data)) / length
freq = np.fft.rfftfreq(length, 1/sampling_rate)


plt.figure(figsize=(10, 5))
plt.plot(freq, dft_result)
plt.title('widmo sygnału po filtracji')
plt.xlabel('Częstotliwość [Hz]')
plt.ylabel('Amplituda')
plt.grid(True)
plt.axvline(60, color='red', linestyle=':')
plt.ylim(0, 0.15)
plt.show()

# roznica przed i po filtracji
roznica = data_ekg_noise[:, 1] - filtered_data
plt.figure(figsize=(10, 5))
plt.plot(data_ekg_noise[:, 0], roznica)
plt.title('Różnica przed i po filtracji')
plt.xlabel('Czas[s]')
plt.ylabel('Wartość')
plt.grid(True)
plt.show()


# widmo roznicy przed i po filtracji
dft_roznica = np.abs(np.fft.rfft(roznica)) / length
freq = np.fft.rfftfreq(length, 1/sampling_rate)

plt.figure(figsize=(10, 5))
plt.plot(freq, dft_roznica)
plt.title('widmo roznicy')
plt.xlabel('Częstotliwość [Hz]')
plt.ylabel('Amplituda')
plt.grid(True)
plt.axvline(60, color='red', linestyle=':')
plt.show()
```


Figure



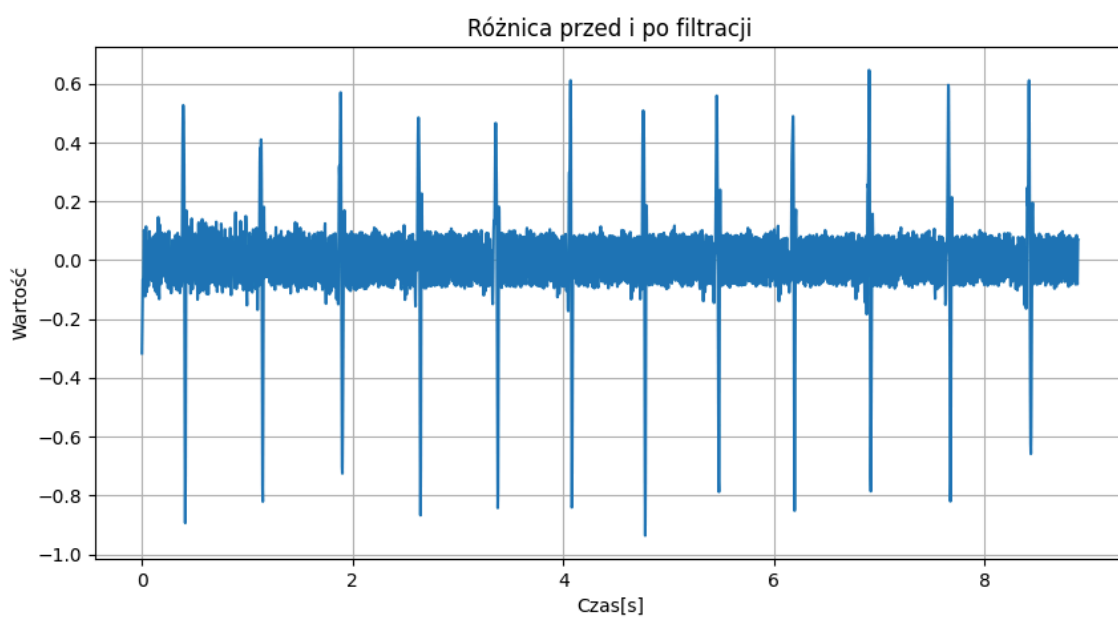
Figure




Figure



Figure



Figure



Zastosowany tutaj filtr jest filtrem dolnoprzepustowym Butterworth'a o rzędzie = 10 oraz częstotliwości granicznej = 58Hz. Od rzędu filtra zależy jak szybko wzrastać będzie tłumienie częstotliwości, oraz jego dokładność. Zaobserwować to możemy na wykresie 2 - Charakterystyka Filtra. Poniżej widoczny jest ponownie przedstawiony ten sam wykres, oraz drugi o innych parametrach filtra. Zielona kreska oznacza częstotliwość 60Hz, powyżej której częstotliwości chcemy odfiltrować.


```
In [ ]: # wykreslenie charakterystyki filtra
b, a = sig.butter(10, 58, 'low', fs=360)
w, h = sig.freqz(b, a)
# plt.semilogx(w*360/(2*np.pi), 20 * np.log10(abs(h)))

plt.figure(figsize=(10, 5))
plt.plot(w*360/(2*np.pi), 20 * np.log10(abs(h)))
plt.title('Charakterystyka filtra - rząd = 10, Częstotliwość graniczna = 58 Hz')
plt.xlabel('Częstotliwość [Hz]')
plt.ylabel('Amplituda')
plt.grid(which='both', axis='both')
plt.axvline(60, color='green') # cutoff frequency
plt.show()


# wykreslenie charakterystyki filtra
b, a = sig.butter(1, 60, 'low', fs=360)
w, h = sig.freqz(b, a)
# plt.semilogx(w*360/(2*np.pi), 20 * np.log10(abs(h)))

plt.figure(figsize=(10, 5))
plt.plot(w*360/(2*np.pi), 20 * np.log10(abs(h)))
plt.title('Charakterystyka filtra - rząd = 1, Częstotliwość graniczna = 60 Hz')
plt.xlabel('Częstotliwość [Hz]')
plt.ylabel('Amplituda')
plt.grid(which='both', axis='both')
plt.axvline(60, color='green') # cutoff frequency
plt.show()
```

Figure



Figure



Zastosowany tutaj filtr jest filtrem dolnoprzepustowym Butterworth'a o rzędzie = 10 oraz częstotliwości granicznej = 58Hz. Od rzędu filtra zależy jak szybko wzrastać będzie tłumienie częstotliwości, oraz jego dokładność. Zaobserwować to możemy na wykresie 2 - Charakterystyka Filtra. Powyżej widoczny jest ponownie przedstawiony ten sam wykres, oraz drugi o innych parametrach filtra. Zielona kreska oznacza częstotliwość 60Hz, powyżej której częstotliwości chcemy odfiltrować.

3. Zastosuj następnie, do sygnału otrzymanego w punkcie 2, filtr górnoprzepustowy o częstotliwości granicznej 5 Hz w celu eliminacji pływania linii izoelektrycznej. Sporządź wykresy sygnałów jak w punkcie 2

```
In [ ]: # filtr górnoprzepustowy - 5Hz i sygnał po filtracji
sos = sig.butter(4, 5, 'highpass', output='sos', fs=360)
```

```
filtered_data_2 = sig.sosfilt(sos, filtered_data)
length_2 = len(filtered_data_2)

plt.figure(figsize=(10, 5))
plt.plot(data_ekg_noise[:, 0], filtered_data_2)
plt.title('Sygnał po filtracji gornoprzepustowym Butterwortha')
plt.xlabel('Czas[s]')
plt.ylabel('Wartość')
plt.grid(True)
plt.xlim(0, 4)
plt.show()

# charakterystyka
b, a = sig.butter(4, 5, 'highpass', fs=360)
w, h = sig.freqz(b, a)

plt.figure(figsize=(10, 5))
plt.plot(w*360/(2*np.pi), 20 * np.log10(abs(h)))
plt.title('Charakterystyka filtra')
plt.xlabel('Frequency [Hz]')
plt.ylabel('Amplitude')
plt.grid(which='both', axis='both')
plt.axvline(5, color='green') # cutoff frequency
plt.show()

# widmo po filtracji
dft_result = np.abs(np.fft.rfft(filtered_data_2)) / length_2
freq = np.fft.rfftfreq(length_2, 1/sampling_rate)

plt.figure(figsize=(10, 5))
plt.plot(freq, dft_result)
plt.title('widmo sygnału po filtracji')
plt.xlabel('Częstotliwość [Hz]')
plt.ylabel('Amplituda')
plt.grid(True)
plt.axvline(5, color='red', linestyle=':')
plt.axvline(60, color='red', linestyle=':')
plt.show()

# roznica przed i po filtracji
roznica_2 = filtered_data - filtered_data_2
plt.figure(figsize=(10, 5))
plt.plot(data_ekg_noise[:, 0], roznica_2)
plt.title('roznica przed i po filtracji')
plt.xlabel('Czas[s]')
plt.ylabel('Wartość')
plt.grid(True)
plt.show()


# widmo roznicy przed i po filtracji
dft_roznica_2 = np.abs(np.fft.rfft(roznica_2)) / length_2
freq = np.fft.rfftfreq(length_2, 1/sampling_rate)

plt.figure(figsize=(10, 5))
plt.plot(freq, dft_roznica_2)
plt.title('widmo roznicy')
plt.xlabel('Częstotliwość [Hz]')
plt.ylabel('Amplituda')
plt.grid(True)
plt.axvline(5, color='red', linestyle=':')
```

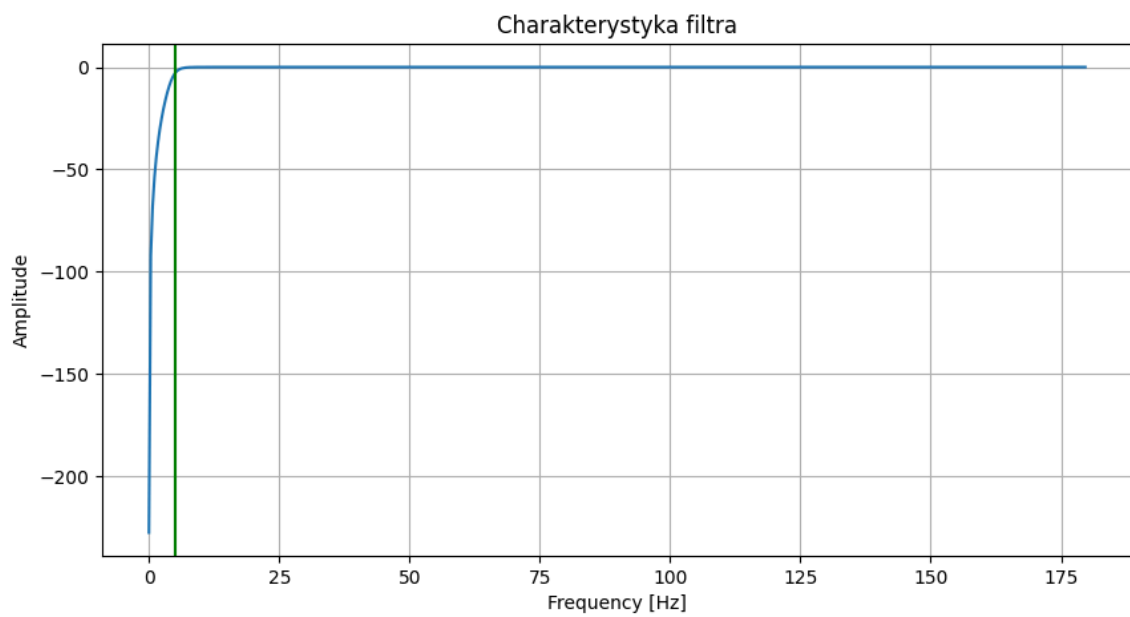


```
plt.axvline(60, color='red', linestyle=':')  
plt.ylim(0, 0.15)  
plt.show()
```


Figure



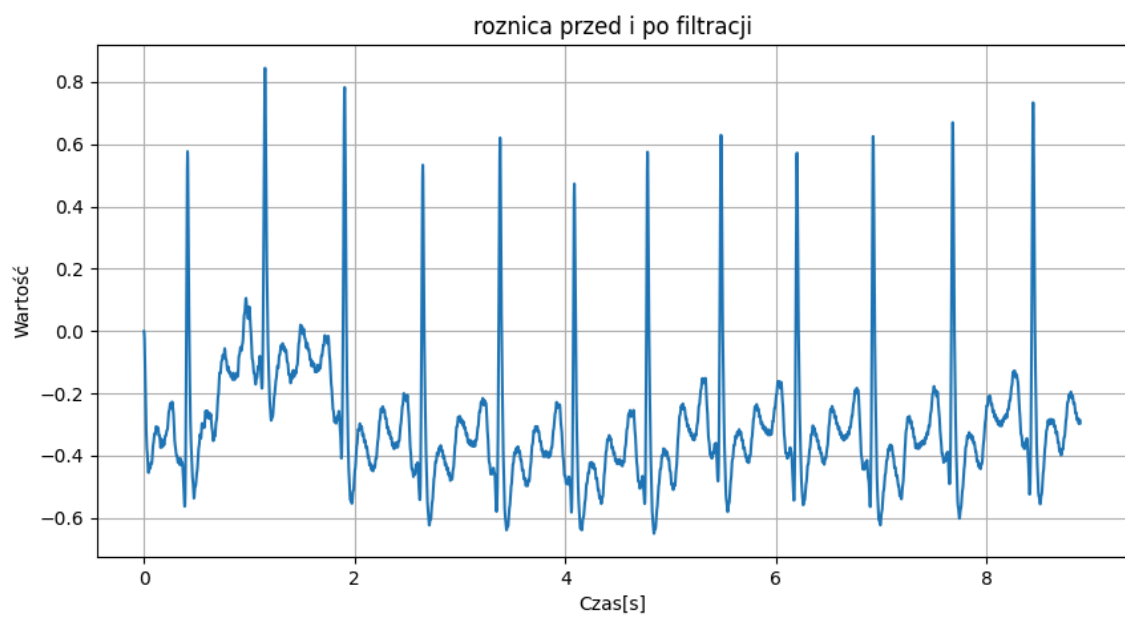
Figure



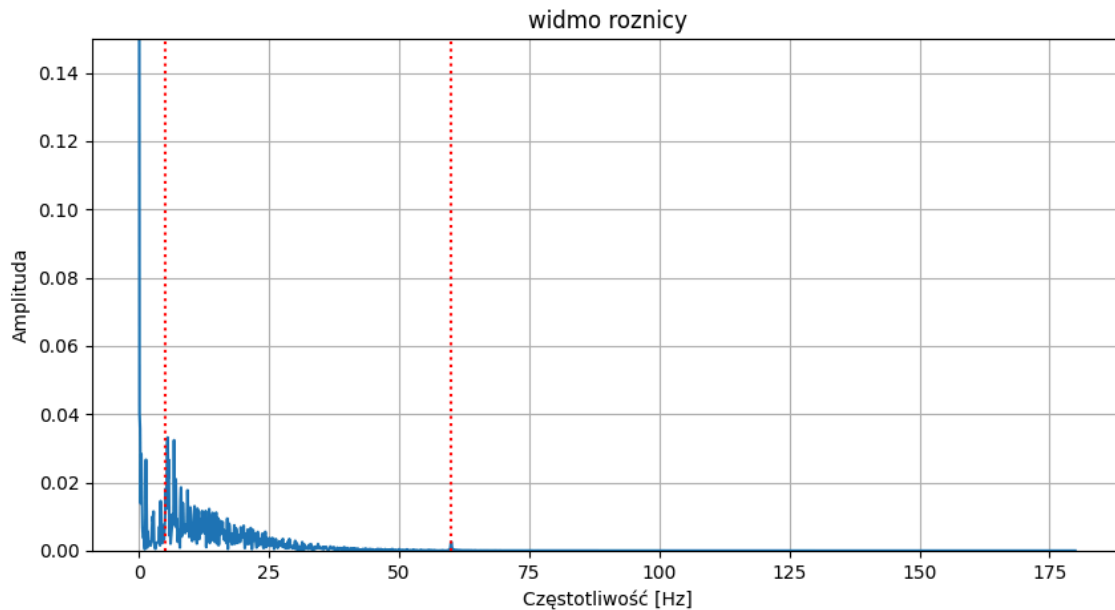
Figure



Figure



Figure



Na końcu przedstawione zostało porównanie fragmentu sygnału otrzymanego po filtracji górnoprzepustowym filtrem Butterwortha (wcześniej także dolnoprzepustowym), z odpowiednim fragmentem oryginalnego sygnału.

```
In [ ]: global ekg_100_time, data_ekg_100

fig, (ax1, ax2) = plt.subplots(2, 1, figsize=(8, 8))
ax1.plot(data_ekg_noise[:, 0], filtered_data_2)
ax1.set_title('ekg_noise - Sygnał po filtracji gornoprzepustowym Butterwortha')
ax1.set_xlabel('Czas [s]')
ax1.set_ylabel('Amplituda')
ax1.set_xlim(data_ekg_noise[:, 0][0], 3)

ax2.plot(data_ekg_noise[:, 0], data_ekg_noise[:, 1])
ax2.set_title('ekg_noise.txt - oryginalny sygnał')
ax2.set_xlabel('Czas [s]')
ax2.set_ylabel('Amplituda')
ax2.set_xlim(data_ekg_noise[:, 0][0], 3)
plt.tight_layout()
plt.show()
```

Figure

